编程学习行为与知识掌握可视分析

第一次作业 A 模块 学生与班级分析

组号：第 X 组　主要完成人：A 同学姓名待填　学号：待填

提交日期：2026 年 11 月 24 日

1 项目概述与数据下载

1.1 项目目标与模块范围（A 同学姓名待填）

我们选择 ChinaVis 2024“析数启智”时序多变量教育数据可视分析题目。本模块完成学生与班级数据的获取、理解、质量检查和第一轮处理，比较班级参与规模、提交频度与作答得分表现，为后续学习行为和知识诊断提供基础。

数据包含 1364 名学生、15 个班级和 232818 条原始提交记录。修复班级字段并按完整业务字段去重后，231811 条提交可关联学生信息。每题取最终有效作答后，全体学生平均得分率为 75.74%。该数值描述已作答题目的表现，不代表全部课程知识掌握度。

1.2 数据来源与目录（A 同学姓名待填）

官方赛题：https://chinavis.org/2024/challenge.html
数据包：https://chinavis.org/2024/document/first_data.zip
数据说明：https://chinavis.org/2024/document/first_dataDes.docx

原始数据保存在 data/raw/chinavis2024_education 中，分析程序读取原件并另存结果。外层乱码目录已重命名；__MACOSX 及以._开头的辅助文件不参与分析。下载和解压记录截图可在小组合并文档时补充。

数据文件	实际规模	作用
Data_StudentInfo.csv	1364 行	学生匿名属性
Data_TitleInfo.csv	44 行 38 道题	题目分值与知识点关系
Data_SubmitRecord 目录	15 个 CSV 232818 行	按班级保存的提交记录

2 数据理解

2.1 学生属性与班级信息（A 同学姓名待填）

字段	含义与用途	检查结果
student_ID	学生匿名编号 关联键	1364 个唯一编号
sex	性别类别	男 683 人 女 681 人
age	学生年龄	18 至 24 岁
major	匿名专业编码	5 种 不推断真实专业名称
class	日志中的班级	15 个有效班级
index	原文件行序号	不作为唯一提交标识

2.2 提交记录与题目分值（A 同学姓名待填）

提交记录通过 student_ID 关联学生表，通过 title_ID 关联题目信息。日志 score 表示提交得分，题目表 score 在本轮作为题目满分 full_score 使用。正式课程报告应与官方数据说明核对这一语义。题目表同一道题可能对应多个知识点，因此先得到每题唯一分值，再与日志进行多对一连接。38 道题均未发现分值冲突，关联前后日志数保持一致。

重复检查使用 class、student_ID、title_ID、time、state、score、method、memory、timeconsume 九个字段。method、memory 和 timeconsume 用于区分提交，不将程序运行耗时解释为学生思考时间。

2.3 关联结构与数据范围（A 同学姓名待填）

关联流程为：学生表 → 按 student_ID 连接提交记录 → 按 title_ID 连接每题唯一分值 → 汇总学生指标 → 汇总班级指标。

班级成员关系由日志中出现的学生推得。无法据此确认未提交学生的班级归属，因此班级人数统一称为“参与学生数”，不计算班级完整名册参与率。

3 数据过滤与质量检查

3.1 学生信息检查（A 同学姓名待填）

学生表五个字段均无缺失，学生编号唯一，未发现完全重复行。本轮保留全部 1364 条学生记录。年龄值 18 至 24 岁未出现明显越界，但取值合理不等于所有属性均已验证真实。

3.2 异常字段与重复日志处理（A 同学姓名待填）

问题	处理依据与方法	数量
班级值为 class	结合来源文件及同一学生其他记录修复 保留修复日志	6 条
学生编号无法关联	编号尾部多 D 但身份未确认 不自动改号 排除于学生关联分析	1 条
完整业务字段重复	992 组共 1998 条 每组保留读取顺序第一条	排除 1006 条
分值或时间异常	检查分值缺失或非正 得分非数值 越界及时间非数值	0 条
最终时刻成绩冲突	同一学生同题最晚时刻有不同得分则不计算该组合	0 组

日志没有已确认的唯一提交 ID；时间数字均为整数，不能据此确认原始采集精度。因此去重属于第一轮分析约定，仍可能将同一时间单位内真实且结果完全相同的提交合并。我们保留全部原始文件、被排除记录和去重前后班级统计，便于复核与调整。

3.3 数据量核对（A 同学姓名待填）

232818 条原始日志 → 修复 6 条班级值但不减行 → 按规则排除 1006 条 → 剩 231812 条 → 排除 1 条无法匹配学生的记录 → 231811 条用于学生与班级分析。处理后不存在跨班级学生；1364 名学生全部具有可关联记录。

4 数据处理方法

4.1 指标定义与计算口径（A 同学姓名待填）

指标	计算方法
参与学生数	班级中可关联学生编号的不同取值数
提交量	去重并成功关联学生信息后的记录数
人均提交量	班级提交量除以参与学生数
参与题量	每名学生提交过的不同题目数
题目得分率	本次得分除以题目分值
学生平均得分率	每题取最终有效作答的得分率 再对该学生有结果的题目等权平均
班级平均得分率	先计算学生平均得分率 再在班级内对学生等权平均

“最终有效作答”是通过分值与时间检查后，按数值时间选择同一学生同题最晚记录，不筛除错误答题状态。未作答题目不计零，真实零分保留；最终时刻若有不同分数则标记歧义。当前得到 50482 个学生与题目组合，未出现最终时刻成绩歧义。

4.2 数据输出与复现（A 同学姓名待填）

scripts/a_students.py 完成学生检查、班级修复、重复审计、日志去重和参与图表。

scripts/a_scores.py 读取前一步的去重日志，生成学生汇总、班级成绩表和箱线图。按此顺序运行可复现结果。

主要输出包括 tables/student_summary.csv、tables/class_summary_deduplicated.csv、tables/class_score_summary.csv。figures 保存图像，audit 保存修复与排除记录，intermediate 保存可重新生成的中间结果。

运行命令：

.\.venv\Scripts\python.exe scripts/a_students.py

.\.venv\Scripts\python.exe scripts/a_scores.py

5 学生构成与班级参与分析

5.1 年龄分布（A 同学姓名待填）

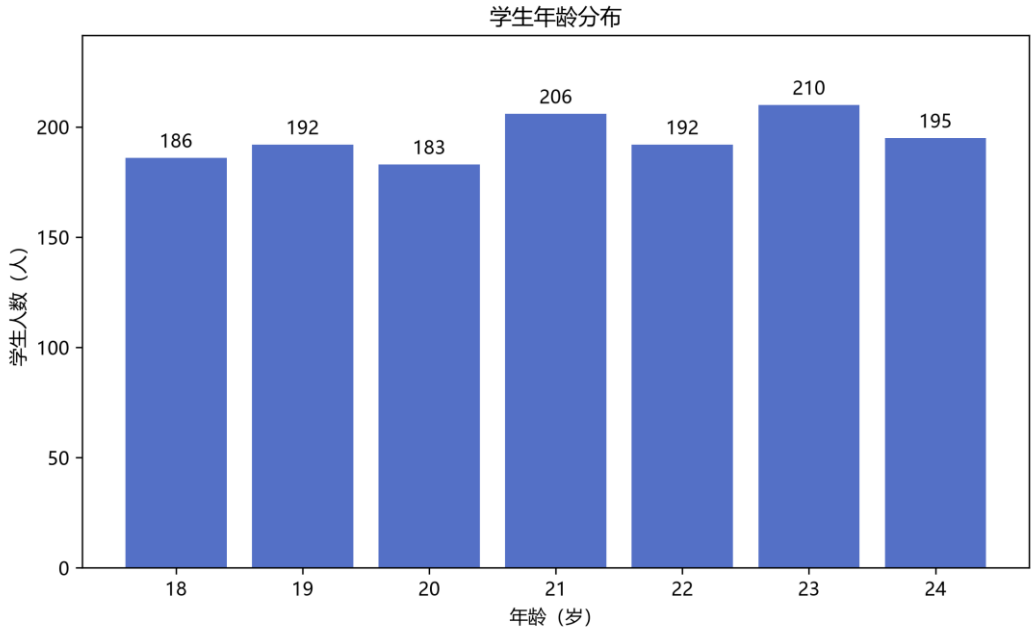


图 1 学生年龄分布

年龄组人数为 183 至 210 人，23 岁最多 210 人，20 岁最少 183 人，相差 27 人。性别人数接近，专业编码人数为 258 至 291 人。这些是样本构成描述，不能据此推断其对成绩的影响。

5.2 班级参与规模（A 同学姓名待填）

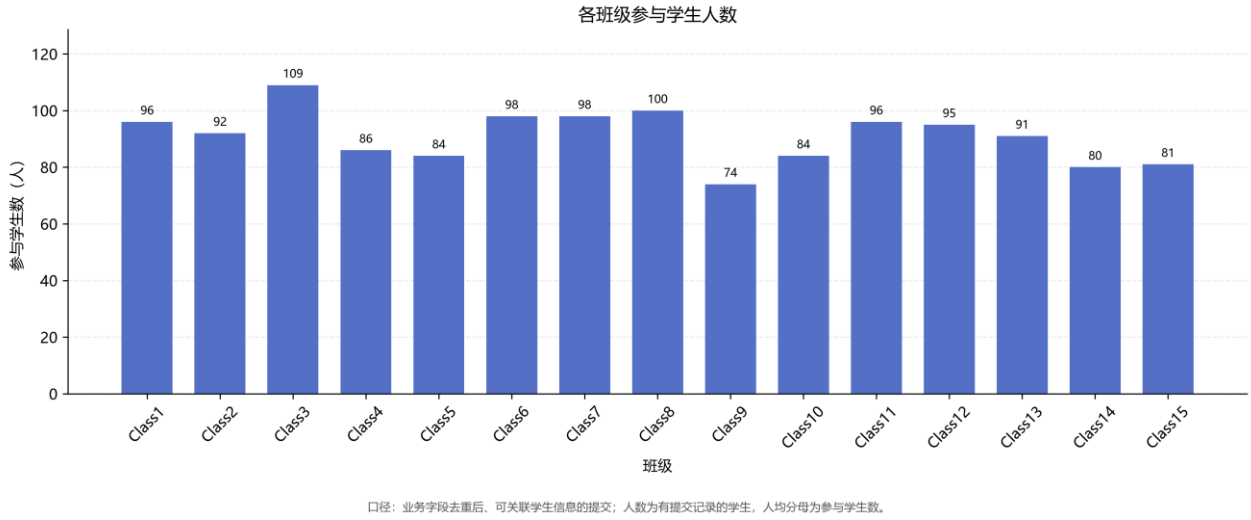


图 2 去重并成功关联学生信息后的班级参与人数

班级参与人数为 74 至 109 人，Class3 最多，Class9 最少。因此比较提交活动时同时使用人均指标，减少班级规模差异的影响。

6 提交频度与班级成绩分析

6.1 人均提交量（A 同学姓名待填）

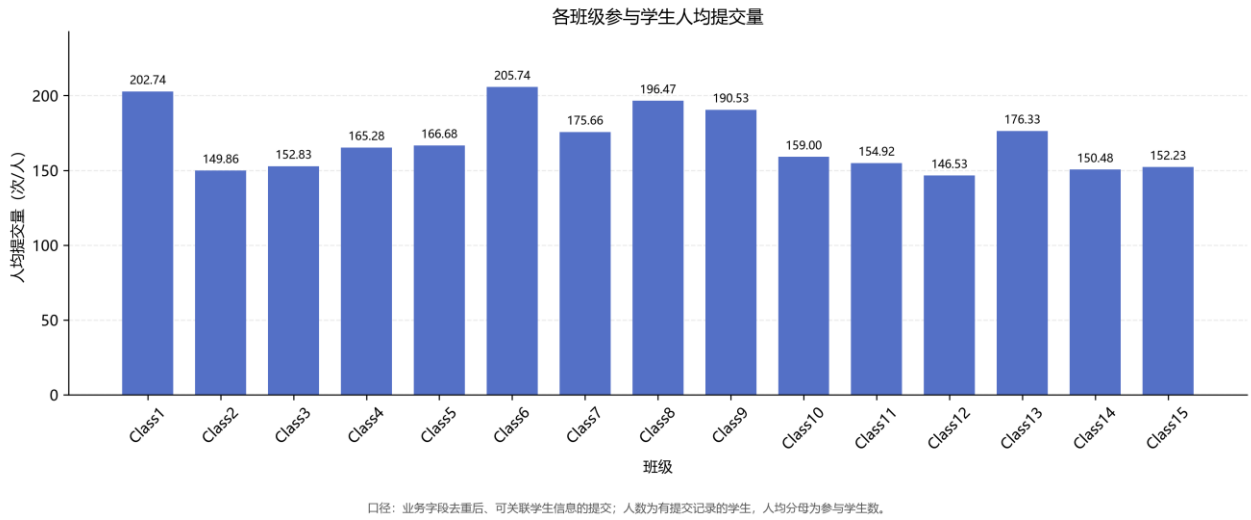


图 3 各班级参与学生人均提交量

Class6 人均提交 205.74 次，Class12 为 146.53 次，两者相差 59.21 次。提交频度可能受到题量、反复尝试及任务安排影响，不能直接解释为学习积极性或学习效果。

6.2 学生得分率分布（A 同学姓名待填）

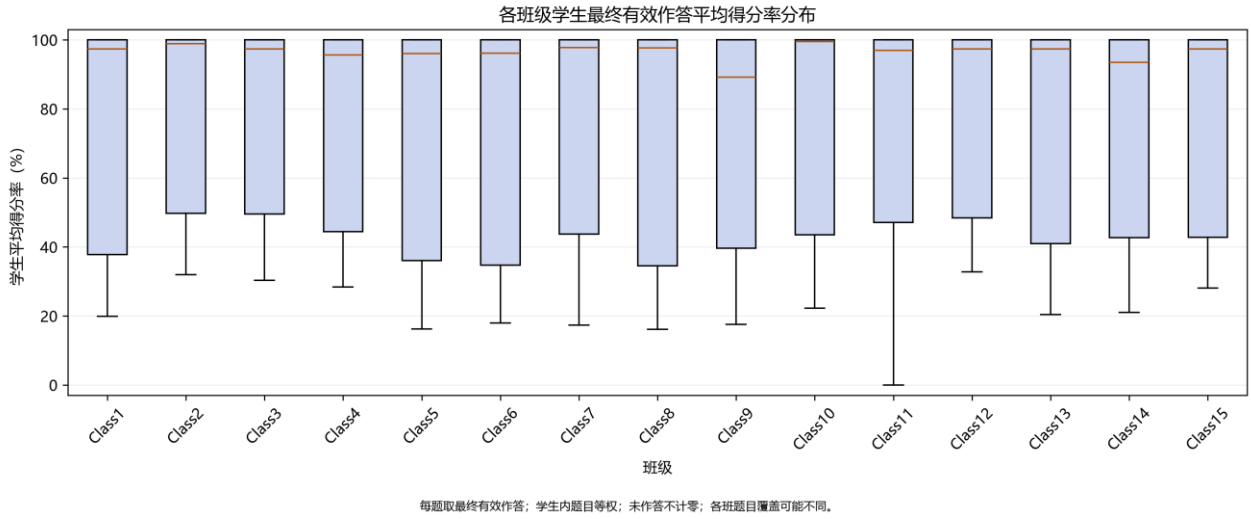


图 4 学生最终有效作答平均得分率的班级分布

箱体表示学生得分率的中间 50%，中线表示中位数，点表示按箱线图规则标出的离群观测，并非错误数据。图表展示班级内个体差异，帮助避免只看平均数。

7 班级结果与解释边界

7.1 班级成绩统计（A 同学姓名待填）

班级	参与人数	平均得分率	中位得分率	人均计分题量
Class1	96	74.86%	97.37%	37.21
Class2	92	79.84%	98.90%	37.22
Class3	109	81.22%	97.37%	36.99
Class4	86	75.90%	95.61%	37.31
Class5	84	71.51%	96.05%	36.74
Class6	98	73.67%	96.10%	36.01
Class7	98	77.64%	97.81%	37.39
Class8	100	75.09%	97.70%	37.26
Class9	74	69.76%	89.18%	36.86
Class10	84	75.39%	99.56%	37.21
Class11	96	77.28%	96.93%	36.75
Class12	95	79.18%	97.37%	37.02
Class13	91	75.13%	97.37%	36.80
Class14	80	72.66%	93.47%	37.31
Class15	81	73.76%	97.37%	37.12

全体学生平均得分率为 75.74%。Class3 班级均值最高，为 81.22%；Class9 最低，为 69.76%，相差约 11.46 个百分点。Class6 提交频度最高，但成绩均值并非最高，说明提交量与学习表现不能相互替代。

7.2 第一轮结论与后续验证（A 同学姓名待填）

各学生参与计分题量为 1 至 38 题，班级平均覆盖亦有差异，因此当前成绩比较仅针对各自已作答题目。本轮未控制题目难度、时间范围和学生基础，不能形成教学质量排名或因果结论。后续应在共同题目及统一时间范围内复算，并与首次成绩、最高成绩及保留重复记录的结果进行敏感性比较。

A 模块已完成前四步的第一轮实现。后续由小组统一指标口径，并把学生与班级结果与 B 的学习行为、C 的题目表现和 D 的知识点分析结合；图形映射和交互实现作为下一阶段工作。